TRABAJO T1
CASO DE ESTUDIO: FALLO NOTABLE DE IA

Grupo G2

Inteligencia Artificial Confiable
UCLM

Arantzazu Otal Alberro
Rodrigo Collado Díaz
Gonzalo Torres Aparicio
Ángel García Consuegra Trujillo
Juan José García García

Índice

1. Resumen ejecutivo 2

2. Descripción de los casos 2

Caso I: La policía de Luisiana arrestó a un sujeto erróneamente. 2

Caso II: Sesgos de la vigilancia predictiva de PredPol 2

Caso III: El algoritmo COMPAS presenta un rendimiento deficiente en la predicción de la reincidencia delictiva. 2

3. Análisis de los casos 2

Caso I: La policía de Luisiana arrestó injustamente a un hombre de color mediante el uso de un rostro falso. 2

Cronograma de informes 2

Incidente 3

Medidas 3

Empresas implicadas 3

Caso II: Sesgos de la vigilancia predictiva de PredPol 4

Cronograma de informes 4

Incidente 4

Medidas 4

Empresas implicadas 5

Caso III: El algoritmo COMPAS presenta un rendimiento deficiente en la predicción de la reincidencia delictiva. 5

Cronograma de informes 5

Incidente 5

Medidas 6

Empresas implicadas 6

4. Lecciones y recomendaciones 6

5. Referencias 7

ANEXO I: Porcentaje de distribución del trabajo 7

ANEXO II: Uso responsable de la IA 7

1. Resumen ejecutivo

Este informe examina tres incidentes en el sistema de justicia de EE.UU. donde la IA perjudicó a minorías raciales debido a datos históricos sesgados, opacidad algorítmica y exceso de confianza en sus resultados. Para lograr una IA confiable, se destaca la necesidad de garantizar equidad demográfica, supervisión humana obligatoria, transparencia y una definición explícita de un trato justo.

2. Descripción de los casos

Caso I: La policía de Luisiana arrestó a un sujeto erróneamente.

La policía de Luisiana utilizó una coincidencia falsa de reconocimiento facial y obtuvo una orden de arresto contra un hombre negro por robos que no cometió.

Caso II: Sesgos de la vigilancia predictiva de PredPol

Los algoritmos de predicción policial, diseñados para ayudar a las fuerzas del orden a predecir delitos futuros, muestran indicios de sesgo en sus resultados.

Caso III: El algoritmo COMPAS presenta un rendimiento deficiente en la predicción de la reincidencia delictiva.

El algoritmo **COMPAS**, utilizado en el sistema judicial para medir el riesgo de reincidencia, no resultó más preciso que personas sin formación elegidas al azar. Según la clasificación del Center for Security and Emerging Technology (CSET), esto provoca un daño real (detenciones y encarcelamientos injustos o desproporcionados) que priva a los acusados de su libertad física y autonomía.

3. Análisis de los casos

Caso I: La policía de Luisiana arrestó injustamente a un hombre negro mediante el uso de un rostro falso.

Ubicación	DeKalb (lugar de arresto) y Baton Rouge (lugar de error identificativo)
Fecha del incidente	25/11/2022
Recuento de informes	6
Subdominio de riesgo	1.3. Desempeño desigual entre grupos
Dominio de riesgo	Discriminación y toxicidad
Entidad	IA
Momento	Tras el despliegue
Intención	Involuntario

Cronograma de informes

2022: 25 noviembre, arresto erróneo.

2023: Noticias relacionadas con el caso:

- La policía de JPSO utilizó tecnología de reconocimiento facial para arrestar a un hombre. La tecnología falló.
- Según un abogado, una herramienta de reconocimiento facial provocó una detención errónea.
- El reconocimiento facial lleva a la policía de Luisiana a arrestar a un hombre inocente.
- Un hombre negro fue encarcelado injustamente durante una semana tras un error en el reconocimiento facial, según un informe.

- La policía de Luisiana utiliza tecnología de reconocimiento facial para arrestar a la persona equivocada por una serie de robos.

Incidente

- El Departamento de Policía de Baton Rouge adoptó la identificación de Reid realizada por la Oficina del Sheriff de la Parroquia de Jefferson (JPSO) para obtener una orden de arresto alegando que estaba entre los 3 hombres involucrados en otro robo de un bolso de 10.000 dólares la misma semana en una tienda en Jefferson Highway.
- La policía local detuvo a Reid el 25 de noviembre mientras conducía por la Interestatal 20 en el condado de Dekalb, Georgia, de camino a una celebración tardía de Acción de Gracias con su madre.
- Ingresó como fugitivo, pero fue puesto en libertad el 1 de diciembre. Los detectives de la Oficina del Sheriff de Jefferson Parish admitieron el error y anularon la orden de arresto.
- La JPSO y la policía de Baton Rouge guardaron silencio sobre el arresto de Reid y su sistema de reconocimiento facial, rechazando dar acceso a la orden judicial alegando una investigación en curso. Dicha orden, firmada por la jueza Eboni Rose, omite explicar el método exacto con el que la oficina de Lopinto identificó al detenido.

Medidas

- En los últimos años, algunas ciudades y estados han restringido el uso del reconocimiento facial por parte de la policía. Sin embargo, varios, entre ellos Nueva Orleans, han dado marcha atrás en este sentido ante el aumento de la delincuencia.
- En Luisiana, se sabe poco sobre el uso del reconocimiento facial fuera de Nueva Orleans, el ayuntamiento este año levantó una prohibición de 2 años y estableció algunas normas.
- La policía de Nueva Orleans limita el uso del reconocimiento facial a la generación de pistas. Las nuevas normas municipales exigen que los agentes obtengan aprobación de sus superiores y que cualquier posible coincidencia sea revisada por otros investigadores de la tecnología.

Empresas implicadas

Los informes publicados por el Centro de Fusión en 2021 indican que emplea a dos proveedores de reconocimiento facial:

- **Clearview AI** presume de tener "la red facial más grande del mundo", con decenas de miles de millones de imágenes "obtenidas de fuentes web exclusivamente públicas, incluidos medios de comunicación, sitios web de fotos policiales, redes sociales públicas y muchas otras fuentes abiertas.
- **Morphotrak** es una empresa francesa que presume de tener cientos de clientes gubernamentales para sus productos de reconocimiento facial.

El creciente interés por el reconocimiento facial coincide con el **auge de los servicios policiales**, cada vez más reducidos, que recurren a una proliferación de cámaras públicas interconectadas para combatir el crimen, y con la mejora de los algoritmos.

Algunos críticos han argumentado que esta tecnología es tan peligrosa en manos del gobierno que debería prohibirse. El Centro de Información sobre Privacidad Electrónica sostuvo este año que el reconocimiento facial es **intrínsecamente peligroso**, ya que permite una vigilancia pública integral.

Caso II: Sesgos de la vigilancia predictiva de PredPol

Ubicación	Estados Unidos (principalmente California (Oakland y Los Ángeles), extendido a decenas de departamentos policiales en todo el país)
Fecha del incidente	18/11/2015
Recuento de informes	17
Subdominio de riesgo	1.1. Discriminación injusta y tergiversación
Dominio de riesgo	Discriminación y toxicidad
Entidad	IA
Momento	Tras el despliegue
Intención	Involuntario

Cronograma de informes

- **Noviembre 2015:** Primeros reportes y análisis académicos que alertan de que los modelos de policía predictiva concentran desproporcionadamente las patrullas en áreas de minorías raciales en Oakland.
- **Febrero – Marzo 2016:** Cobertura de medios especializados que denuncia el riesgo de etiquetar a inocentes como sospechosos a partir de historiales policiales y abre el debate público sobre el uso de la IA como vector de perfilamiento racial.
- **Octubre – Noviembre 2016:** Publicación del estudio de HRDAG (To predict and serve?), que aplica el algoritmo a datos de delitos de drogas de Oakland y demuestra empíricamente que el algoritmo refuerza la discriminación policial mediante bucles de retroalimentación basados en arrestos pasados y no en el delito real.
- **2017 - 2019:** Auditorías comunitarias, de libertades civiles y coberturas periodísticas en profundidad (como Vice y medios locales) revelan descontento vecinal por sobrevigilancia y cuestionan la validez científica del modelo en departamentos como el LAPD.
- **2020 - 2021:** El LAPD abandona PredPol en abril de 2020 sin haber podido medir su eficacia para reducir el delito, y la empresa cambia su nombre a Geolitica.
- **Diciembre 2021:** Investigación exhaustiva de The Markup en colaboración con Gizmodo tras analizar millones de predicciones de PredPol, confirmando patrones de focalización sistemática en vecindarios pobres, de personas negras y latinos. La policía de Oakland descarta la compra de PredPol, valorada en 150.000 dólares, por sus posibles consecuencias no deseadas.
- **2023:** «2023: SoundThinking (antes ShotSpotter) absorbe el equipo, las patentes y los clientes de Geolitica, que cesa su actividad a finales de año.»

Incidente

El **software de patrullaje predictivo PredPol** utilizaba registros policiales históricos (llamadas de alerta, tipos de delitos, coordenadas geográficas y marcas temporales) procesados mediante algoritmos derivados del modelado sismológico (procesos puntuales de Hawkes) para pronosticar celdas de cuadrícula donde era más probable que ocurrieran futuros delitos. Al desplegarse en ciudades como Oakland y Los Ángeles, el algoritmo recomendó patrullar reiteradamente vecindarios habitados mayoritariamente por minorías raciales y personas de bajos ingresos. Al enviar más agentes a esas áreas, se incrementó el número de intervenciones y detenciones registradas allí, alimentando de nuevo el software y creando un bucle cerrado de sobrevigilancia y discriminación que no reflejaba necesariamente las tasas reales de criminalidad.

Medidas

- Retirada del software y fin de contratos: Diversos departamentos policiales (como el de Los Ángeles, Oakland y Nueva Orleans) cesaron el uso de la herramienta ante la presión social y la falta de evidencia de reducción del delito.

- Auditorías algorítmicas externas: Intervención de organizaciones de derechos civiles (como HRDAG, EFF y la ACLU), que lograron abrir el debate sobre la falta de validez de los datos de arrestos como variable objetivo (ground truth).
- Restricciones regulatorias locales y estatales: Implementación de moratorias y normativas de supervisión comunitaria de tecnologías de vigilancia en varias ciudades estadounidenses.
- Rebranding corporativo: PredPol cambió su denominación comercial a Geolitica e intentó orientar sus métricas hacia la gestión de recursos antes de anunciar el cierre de operaciones de esa plataforma.

Empresas implicadas

- PredPol, Inc. (posteriormente renombrada como Geolitica): Empresa desarrolladora y proveedora del algoritmo comercial de policía predictiva.
- Departamentos de policía colaboradores/clientes: Entre los principales desplegados en los informes figuran el Departamento de policía de Oakland (OPD) y el Departamento de policía de Los Ángeles (LAPD), además de otros cuerpos policiales locales en EE. UU.

Caso III: El algoritmo COMPAS presenta un rendimiento deficiente en la predicción de la reincidencia delictiva.

Ubicación	Estados Unidos (condado de Broward, Florida, y estado de Wisconsin)
Fecha del incidente	23/05/2016
Recuento de informes	21
Subdominio de riesgo	1.1. Discriminación injusta y tergiversación
Dominio de riesgo	Discriminación y toxicidad
Entidad	IA
Momento	Tras el despliegue
Intención	Involuntario

Cronograma de informes

- **Mayo 2016**: ProPublica publica su investigación sobre COMPAS y la metodología de su análisis, en la que denuncia que la herramienta se equivoca de forma distinta según la raza del acusado.
- **Julio 2016**: Northpointe, la empresa desarrolladora, responde que la herramienta es igual de precisa para ambos grupos.
- **2016 – 2017**: El caso Loomis llega a los tribunales. Un condenado impugnó la sentencia alegando que COMPAS vulneraba su derecho a un proceso con garantías, porque no podía rebatir la puntuación.
- **2017**: MIT Technology Review y una tribuna de opinión en The New York Times amplían el debate sobre el sesgo y la opacidad de los algoritmos en el sistema penal.
- **Enero 2018**: Dressel y Farid (Dartmouth College) publican en Science Advances el estudio que da nombre al incidente, con una amplia cobertura en The Verge, The Atlantic, The Economist y The Guardian, entre otros.
- **2018 – 2020**: Siguen los análisis del Foro Económico Mundial y de Privacy International, y en 2020 la organización Upturn presenta un escrito amicus curiae que reclama una revisión independiente del software utilizado en el sistema penal.

Incidente

COMPAS (Correctional Offender Management Profiling for Alternative Sanctions) es una herramienta comercial que calcula el riesgo de reincidencia de un acusado a partir de un cuestionario de 137 factores, y sus predicciones se usan en decisiones de libertad provisional, condena y libertad condicional.

En 2016, **ProPublica** analizó a más de 10.000 acusados del condado de Broward (Florida) y comprobó que la herramienta solo acertaba en el 61 % de los casos. Además, los errores no se repartían por igual: entre quienes no volvieron a delinquir, el 44,9 % de los acusados negros había sido clasificado como de alto riesgo, frente al 23,5 % de los blancos. En 2018, un estudio de Dartmouth demostró que un grupo de personas sin formación acertaba algo más que **COMPAS** (67 % frente a 65 %) y que un modelo lineal con solo dos variables igualaba su rendimiento.

Medidas

- **Respuesta del fabricante:** Northpointe rechazó las conclusiones de ProPublica y defendió que su herramienta trata por igual a ambos grupos según su propio criterio de equidad.
- **Vía judicial:** En el caso *Loomis* (2016), el Tribunal Supremo de Wisconsin permitió seguir usando COMPAS. Eso sí, exigió advertir a los jueces de sus limitaciones y que la puntuación nunca fuera el factor determinante de la condena. El Tribunal Supremo de EE. UU. no admitió el recurso en 2017.
- **Datos abiertos:** ProPublica publicó sus datos y su código en GitHub, y el conjunto de datos de Broward se convirtió en una referencia para la investigación sobre equidad algorítmica.
- **Revisión independiente:** Organizaciones como Upturn reclaman que el software usado en el sistema penal se someta a una revisión independiente y contradictoria.

Empresas implicadas

- Northpointe, Inc. (desde 2017, Equivant): la AIID la señala como desarrolladora e implantadora del sistema, y a las personas acusadas como afectadas.
- Administraciones usuarias: Tribunales y servicios penitenciarios de varios estados. En el caso analizado, ProPublica obtuvo las puntuaciones de la Oficina del Sheriff de Broward, que usaba COMPAS en las decisiones de libertad provisional.

4. Lecciones y recomendaciones

Los tres casos muestran que los fallos no se deben solo a la tecnología, influyen los datos con los que se entrena, cómo se usa el sistema y la falta de control sobre él. A partir de ellos proponemos cinco recomendaciones:

1. **Cuidar los datos de entrenamiento.** PredPol y COMPAS aprendieron de datos de arrestos, que reflejan dónde patrulla la policía más que dónde se cometen los delitos. Hay que revisar el origen de los datos y no tratar como verdad objetiva lo que en realidad es el resultado de decisiones humanas sesgadas.
2. **Evaluar el rendimiento por grupos**. El reconocimiento facial falla más con personas negras, y COMPAS se equivocaba de forma distinta según la raza. Antes de desplegar un sistema hay que medir sus errores por grupo demográfico, y repetir esa comprobación de forma periódica una vez en uso.
3. **Mantener a una persona en el control**. En Luisiana, una coincidencia facial se convirtió en una orden de arresto sin más comprobaciones. Los resultados de la IA deben tratarse como pistas que alguien verifica, nunca como pruebas, y quienes usan el sistema deben conocer sus límites.
4. **Exigir transparencia y auditoría**. El funcionamiento de COMPAS es secreto comercial, y en el caso de Luisiana la orden de arresto no mencionaba el reconocimiento facial. Los afectados deben saber que se ha usado IA y poder impugnar el resultado, y los sistemas deben someterse a auditorías independientes.

5. **Definir qué es justo antes de diseñar**. El caso COMPAS demuestra que no se pueden cumplir todos los criterios de equidad a la vez. Por eso hay que decidir y justificar de forma explícita cuál se prioriza, en lugar de dejarlo en manos del fabricante.

Estas recomendaciones coinciden con los requisitos de IA fiable de la Comisión Europea y con el Reglamento europeo de IA, que considera de alto riesgo los sistemas usados por las fuerzas del orden y prohíbe la predicción de delitos basada únicamente en perfiles. En definitiva, cuando está en juego la libertad de las personas, la IA debe apoyar la decisión humana, no sustituirla.

5. Referencias

Caso I: Arresto erróneo

→ *Incident 440: Louisiana Police Wrongfully Arrested Black Man Using False Face Match* https://incidentdatabase.ai/cite/440/

→ *AI Incident Database. (s. f.). Randal Quran Reid.* https://incidentdatabase.ai/entities/randal-quran-reid/

→ *Grother, P., Ngan, M. y Hanaoka, K. (2019). Face Recognition Vendor Test (FRVT) Part 3: Demographic Effects (NISTIR 8280). NIST.* https://doi.org/10.6028/NIST.IR.8280

→

Caso II: Predpol

→ *Incident 54: Predictive Policing Biases of PredPol* https://incidentdatabase.ai/cite/54/

→ *Sankin, A., Mehrotra, D., Mattu, S. y Gilbertson, A. (2021). Crime Prediction Software Promised to Be Free of Biases. New Data Shows It Wasn't. The Markup.* https://themarkup.org/prediction-bias/2021/12/02/crime-prediction-software-promised-to-be-free-of-biases-new-data-shows-it-wasnt

→ *Lum, K. e Isaac, W. (2016). To predict and serve? Significance, 13(5), 14–19.* https://doi.org/10.1111/j.1740-9713.2016.00960.x

→ *Media Alliance. (2017). Oakland Police Department rejects predictive policing.* https://media-alliance.org/2017/02/oakland-police-department-rejects-predictive-policing/

→ *The Markup. (2021). How we determined crime prediction software disproportionately targeted low-income, Black, and Latino neighborhoods.* https://themarkup.org/show-your-work/2021/12/02/how-we-determined-crime-prediction-software-disproportionately-targeted-low-income-black-and-latino-neighborhoods

→

Caso III: Algoritmo COMPAS

→ *AI Incident Database (2016). Incident 40: COMPAS Algorithm Performs Poorly in Crime Recidivism Prediction.* https://incidentdatabase.ai/cite/40/

→ *Angwin, J., Larson, J., Mattu, S. y Kirchner, L. (2016). Machine Bias. ProPublica.* https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing

→ *Larson, J. et al. (2016). How We Analyzed the COMPAS Recidivism Algorithm. ProPublica.* https://www.propublica.org/article/how-we-analyzed-the-compas-recidivism-algorithm

→ *Dressel, J. y Farid, H. (2018). The accuracy, fairness, and limits of predicting recidivism. Science Advances, 4(1).* https://www.science.org/doi/10.1126/sciadv.aao5580

→ *Harvard Law Review (2017). State v. Loomis.* https://harvardlawreview.org/print/vol-130/state-v-loomis/

→ *Kleinberg, J., Mullainathan, S. y Raghavan, M. (2016). Inherent Trade-Offs in the Fair Determination of Risk Scores.* https://arxiv.org/abs/1609.05807
→ *Chouldechova, A. (2017). Fair prediction with disparate impact: A study of bias in recidivism prediction instruments. Big Data, 5(2).* https://arxiv.org/abs/1703.00056

ANEXO I: Porcentaje de distribución del trabajo

- Arantzazu Otal Alberro 20%
- Rodrigo Collado Díaz 20%
- Gonzalo Torres Aparicio 20%
- Ángel García Consuegra Trujillo 20%
- Juan José García García 20%

ANEXO II: Uso responsable de la IA

En este trabajo se ha usado IA para los siguientes casos: Ordenar y clasificar datos cronológicamente, Traducción de textos a español para facilitar la comprensión lectora, búsqueda de artículos de referencia, resumir textos de estudio.